

Informe Proyecto corte 1

Yslen Natalia Moreno Gutierrez, Oscar Mauricio Peñuela Guerrero

Desempeño

Ambos modelos se evaluaron sobre la misma partición 80/20 estratificada (`random_state=42`). La Tabla 1.1 resume el accuracy antes y después del ajuste con `GridSearchCV` (5 pliegues).

Modelo	Train	Test	CV (ajust.)	Test (ajust.)
Árbol sin ajustar	1.000	0.912	–	–
Árbol ajustado	0.987	–	0.938	0.939
KNN por defecto ($k = 5$)	0.974	0.956	–	–
KNN ajustado	1.000	–	0.974	0.974

Table 1.1: Accuracy antes y después del ajuste de hiperparámetros.

El árbol sin restricciones llega a accuracy 1.000 en entrenamiento pero cae a 0.912 en prueba (sobreajuste). Ajustado (`gini`, `max_depth=4`, `min_samples_split=2`, `min_samples_leaf=1`), sube a 0.939. El KNN ajustado (`n_neighbors=8`, `euclidean`, `distance`) obtiene el mejor resultado global: 0.974 en prueba.

Interpretabilidad

El Árbol de Decisión es más interpretable: su estructura if-else se visualiza directamente y `feature_importances_` indica qué variables explican la separación de clases sin cálculos extra. Las más relevantes fueron *worst radius*, *worst concave points*, *texture error*, *worst texture* y *worst concavity*, dominando *worst radius*. Es consistente con el dominio: las variables “worst” del núcleo celular suelen asociarse a malignidad.

KNN, en cambio, es caja negra: clasifica por distancia a vecinos en el espacio escalado, sin regla explícita ni importancia de variables comparable. Aunque rindió mejor, no explica directamente por qué clasifica un caso como maligno o benigno.

Diagnóstico de sesgo-varianza

Las curvas de aprendizaje muestran que ambos modelos mejoran con más datos, reduciendo la brecha entrenamiento-validación. Las curvas de validación muestran los dos extremos:

- **Árbol:**
 - `max_depth` alto: accuracy de entrenamiento cerca de 1.0 pero validación se estanca (alta varianza).
 - `max_depth` muy bajo: ambos accuracy bajos (alto sesgo).
- **KNN:** $k = 1$ sobreajusta (alta varianza, muy sensible a ruido local). k muy alto promedia de más y pierde discriminación (alto sesgo).

Un árbol muy profundo y un KNN con k muy bajo comparten el mismo problema de fondo: ambos ajustan la predicción a detalles muy específicos del entrenamiento (una hoja casi por muestra; un solo vecino en KNN), así que pequeños cambios en los datos producen predicciones muy distintas, lo cual es, por definición, varianza alta.

Conclusión

KNN ajustado obtuvo mejor accuracy (0.974 vs. 0.939), pero el Árbol de Decisión ofrece mayor interpretabilidad al exponer qué variables impulsan la clasificación. La elección depende del objetivo: desempeño puro (KNN) o explicabilidad clínica (Árbol de Decisión).