

Respuesta escrita

Yslen Natalia Moreno Gutierrez, Oscar Mauricio Peñuela Guerrero

Rank	Variable	Importancia
1	worst radius	0.7335
2	worst concave points	0.1220
3	texture error	0.0458
4	worst texture	0.0323
5	worst concavity	0.0172
6	mean concave points	0.0133
7	area error	0.0127
8	mean texture	0.0118
9	worst symmetry	0.0113

Table 1.1: Importancia de cada variable (reducción de impureza Gini), ordenadas de mayor a menor. Solo 9 de las 30 variables tienen importancia distinta de cero; las 21 restantes no se usaron en ningún split de este árbol.

Importancia de variables

La importancia de las variables se calculó únicamente para el Árbol de Decisión ajustado mediante

`feature_importances_` de `scikit-learn`. Este atributo mide la reducción de impureza Gini aportada por cada variable. KNN no cuenta con un atributo equivalente, por lo que este análisis solo se realizó para el árbol.

Las variables más importantes fueron *worst radius* (73.35%) y *worst concave points* (12.20%), que juntas representan más del 85% de la importancia del árbol. En total, solo 9 de las 30 variables tuvieron una importancia distinta de cero; las otras 21 no fueron utilizadas en los splits.

Este resultado es coherente con el dominio, ya que el tamaño y la forma irregular de los núcleos celulares están relacionados con la malignidad. Además, las variables “worst” suelen ser relevantes porque representan los valores extremos observados en la muestra.

La importancia de las variables puede cambiar dependiendo de los hiperparámetros, la partición de los datos y la correlación entre variables. Por ejemplo, aumentar `max_depth` podría permitir que el árbol utilice más variables. Por esto, que una variable no aparezca en este árbol no significa necesariamente que sea clínicamente irrelevante.

En conclusión, *worst radius* y *worst concave points* fueron las variables más importantes del Árbol de Decisión y concentraron la mayor parte de su capacidad predictiva.